


2024年度
機械学習
第11週

担当教員 小林 邦和

- 第1回 ガイダンス:機械学習の概要
- 第2回 線形モデルによるクラス分類(線形サポートベクトルマシン)
- 第3回 非線形モデルによるクラス分類1(非線形サポートベクトルマシン)
- 第4回 非線形モデルによるクラス分類2(ニューラルネットワーク)
- 第5回 線形モデルによる回帰(線形サポートベクトル回帰)
- 第6回 非線形モデルによる回帰(非線形サポートベクトル回帰)
- 第7回 課題1(クラス分類と回帰)
- 第8回 線形モデルによる次元削減(主成分分析)
- 第9回 非線形モデルによる次元削減(オートエンコーダ)
- 第10回 非階層的クラスタリング(k平均法)
- 第11回 階層的クラスタリング(凝集クラスタリング)
- 第12回 課題2(次元削減とクラスタリング)
- **第13回 強化学習(Q学習,モンテカルロ法,SARSA,Actor-Critic)**
- 第14回 課題3(強化学習)
- 第15回 期末試験

- 強化学習(復習)
- マルコフ決定過程(MDP)
- モンテカルロ法
- Q学習
- SARSA
- Actor-Critic
- 演習(強化学習によるエージェント制御)

強化学習





- 目的

ある与えられた状況下で, 獲得する**報酬が最大となる適切な行動を見つける**という問題を解く

- 適用例


- 行動獲得



ロボットが得る**報酬を最大化する**問題

人間は大脳基底核で強化学習している！

625



出典: 銅谷賢治「脳の各器官ごとの学習アルゴリズムによる機能分化」(1999年)

概念図(強化学習)

626



マルコフ決定過程(MDP)

627

Markov Decision Process

マルコフ性

- 遷移先の状態は直前の状態とそのときに選択した行動のみに依存する
- 報酬は直前の状態と遷移先に依存する

マルコフ決定過程

- 環境がマルコフ性に従う確率過程

エージェントが獲得する報酬の総和 R_t の**最大化**

$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \gamma^3 r_{t+4} + \dots$$

$$= \sum_{\tau=0}^{\infty} \gamma^{\tau} r_{t+\tau+1}$$

r_t : 時刻 t で獲得できる即時報酬

γ : 割引率(将来獲得する報酬を割り引く定数)

$$0 < \gamma < 1$$

モデルフリー強化学習

環境モデル(遷移関数, 報酬関数)が**未知**の場合で,
エージェントを**実際に動作**させて環境モデルを推定

例: モンテカルロ法など


モデルベース強化学習

環境モデルが**既知**の場合で, エージェントを**仮想的に動作**させて環境モデルを学習

例: Q学習, SARSA, Actor-Critic, DQNなど

強化学習(変数の定義)

631



定義

価値関数

政策 π に基づき行動した結果として得られる状態 s の価値

$$V_{\pi}(s_t) = E_{\pi} [R_t]$$

$$= E_{\pi} \left[\sum_{\tau=0}^{\infty} \gamma^{\tau} r_{t+\tau+1} \right]$$

$$= E_{\pi} \left[r_{t+1} + \gamma \sum_{\tau=0}^{\infty} \gamma^{\tau} r_{t+\tau+2} \right]$$

R_{t+2}

$$= E_{\pi} [r_{t+1} + \gamma R_{t+2}]$$

- 政策: $\pi(a|s)$
状態 s のときに行動 a を選択する確率

状態 s の価値関数は報酬関数 $R(s, s')$ を用いて次式のように展開できる

$$V_{\pi}(s) = E_{\pi} [r_{t+1} + \gamma R_{t+2}]$$

ベルマン方程式

$$= \sum_{a \in A} \pi(a|s) \sum_{s' \in S} P(s'|s, a) \{R(s, s') + \gamma V_{\pi}(s')\}$$

- 遷移関数: $P(s'|s, a)$
状態 s で行動 a を選択し, 次の時刻で状態 s' へ遷移する確率
- 報酬関数: $R(s, s')$
現在の状態 s から次の状態 s' へ遷移して得られる報酬の関数
- 状態集合: S
- 行動集合: A

常に価値が最大となる行動 a を選択する場合

$$V^*(s) = \max_{a \in A} \sum_{s' \in S} P(s'|s, a) \{R(s, s') + \gamma V^*(s')\}$$

報酬関数 $R(s, s')$ が現在の状態 s のみで決まる(つまり $R(s)$)場合

$$\begin{aligned} V^*(s) &= \max_{a \in A} \sum_{s' \in S} P(s'|s, a) \{R(s) + \gamma V^*(s')\} \\ &= R(s) + \gamma \max_{a \in A} \sum_{s' \in S} P(s'|s, a) V^*(s') \end{aligned}$$

1. モンテカルロ法
2. Q学習
3. SARSA
4. Actor-Critic

政策

探索と利用の
バランスが重要

ϵ -greedy法

$$\pi(s|a) = \begin{cases} \text{ランダムな行動選択} & (\text{確率}\epsilon) \\ \text{最大Q値の行動選択} & (\text{確率}1 - \epsilon) \end{cases}$$

学習式

行動価値関数の更新式

獲得報酬
(実績)

価値関数
(予測)

$$Q(s, a) = Q(s, a) + \alpha(R - Q(s, a))$$

α : 学習率

政策

ϵ -greedy法

$$\pi(s|a) = \begin{cases} \text{ランダムな行動選択} & (\text{確率}\epsilon) \\ \text{最大Q値の行動選択} & (\text{確率}1 - \epsilon) \end{cases}$$

学習

行動価値関数の更新式

$$Q(s, a) = Q(s, a) + \alpha (r + \gamma \max_{a' \in A} Q(s', a') - Q(s, a))$$

獲得報酬 (予測)

価値関数 (予測)

TD誤差

α : 学習率, γ : 割引率

学習目的

エージェントが環境内で得る報酬の総和 R_t の最大化

$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

$$= \sum_{\tau=0}^{\infty} \gamma^{\tau} r_{t+\tau+1}$$

γ : 割引率

目的関数

政策 π に基づき行動した結果, 得られる状態 s と行動 a の価値

$$\begin{aligned} Q_{\pi}(s, a) &= E_{\pi} [r_{t+1} + \gamma R_{t+2}] \\ &= \sum_{s' \in S} P(s'|s, a) \left(r + \gamma \sum_{a' \in A} \pi(a'|s) Q^{\pi}(s', a') \right) \end{aligned}$$

常に価値が最大となる行動 a を選択する場合

$$Q^*(s, a) = \sum_{s' \in S} P(s'|s, a) \left(r + \gamma \max_{a' \in A} Q^*(s', a') \right)$$

学習式

行動価値関数の更新式


TD誤差 (予測より良い行動の場合に正の値, 悪い行動の場合に負の値を取る)

$$\begin{aligned} Q_{\pi}(s_t, a_t) &\leftarrow Q_{\pi}(s_t, a_t) + \alpha \left(r_{t+1} + \gamma \max_{a_{t+1} \in A} Q_{\pi}(s_{t+1}, a_{t+1}) - Q_{\pi}(s_t, a_t) \right) \\ &\leftarrow (1 - \alpha) Q_{\pi}(s_t, a_t) + \alpha \left(r_{t+1} + \gamma \max_{a_{t+1} \in A} Q_{\pi}(s_{t+1}, a_{t+1}) \right) \end{aligned}$$

α : 学習率(学習の速度を定める定数)

Q学習の仕組み

641



組合せ爆発


広大な状態・行動空間を扱う場合, 組合せ爆発が発生

行動 状態	a_1	a_2	$\dots$	a_M
s_1	$Q(s_1, a_1)$	$Q(s_1, a_2)$	$\dots$	$Q(s_1, a_M)$
s_2	$Q(s_2, a_1)$	$Q(s_2, a_2)$	$\dots$	$Q(s_2, a_M)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
s_N	$Q(s_N, a_1)$	$Q(s_N, a_2)$	$\dots$	$Q(s_N, a_M)$

膨大な
テーブル

入力

状態



出力

解決策

状態・行動空間を深層
ニューラルネットワーク
で近似(DQNなど)

3.SARSA

643

政策

ϵ -greedy法

$$\pi(s|a) = \begin{cases} \text{ランダムな行動選択} & (\text{確率}\epsilon) \\ \text{最大Q値の行動選択} & (\text{確率}1 - \epsilon) \end{cases}$$

学習

行動価値関数の更新式

$$Q(s, a) = Q(s, a) + \alpha (r + \gamma Q(s', a') - Q(s, a))$$

α : 学習率, γ : 割引率

Q学習との相違
($s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a'$)

獲得報酬
(予測)


価値関数
(予測)

TD誤差

4.Actor-Critic法[1/2]

644

政策(Actor)と価値評価(Critic)を分離



4.Actor-Critic[2/2]

645

政策

Softmax関数

$$\pi(s|a) = \frac{p(s, a)}{\sum_{a \in A} p(s, a')}$$

学習

価値関数の更新

$$V(s) = V(s) + \alpha \left(\boxed{r' + \gamma V(s')} - \boxed{V(s)} \right)$$

獲得報酬 (予測) 価値関数 (予測) TD誤差

政策の更新

$$p(s, a) = p(s, a) + \alpha \left(r' + \gamma V(s') - V(s) \right)$$


α : 学習率, γ : 割引率

Q学習 (モデルフリー・価値ベースの強化学習)

646

変数の定義

- 状態: s
- 行動: a
- 報酬: r
- 政策: $\pi(a|s)$
状態 s のときに行動 a を選択する確率
- 遷移確率: $P(s'|s, a)$
状態 s で行動 a を選択し, 次の時刻で状態 s' へ遷移する確率



演習

(強化学習によるエージェント制御)

1. 強化学習フレームワークGymnasiumのインストール

✓ **Google Colab環境**の場合

`!pip install gymnasium`

✓ **ローカル環境**の場合

`pip install gymnasium`

2. ユニパからサンプルコードをダウンロード

ファイル名: `11_Reinforcement_Learning.ipynb`

Frozen Lake問題

環境: 4×4 格子世界

状態: $s_1, s_2, \dots, s_{16}$

スタート: s_1 , ゴール: s_{16}

落とし穴: s_6, s_8, s_{12}, s_{13}

行動: $a_{up}, a_{down}, a_{left}, a_{right}$
上・下・左・右へ1マス移動

報酬: $R = +1$ at s_{16}

ゴール報酬以外なし

スタート



落とし穴

ゴール

4つの強化学習方式の比較

1. モンテカルロ法

2. Q学習

3. SARSA

4. Actor-Critic

エピソード数: 3,000

割引率 γ : 0.9

学習率 α : 0.1 ※モンテカルロ法以外


確率 ε : 初期値0.5, 更新式 $\frac{\varepsilon}{\text{episode}+1}$

(ε -greedy法のランダムな行動選択確率の初期値)

※Actor-Critic以外


獲得報酬の推移(モンテカルロ法)

657



価値関数マップ(モンテカルロ法)


658



s_1 	s_2	s_3	s_4
s_5	s_6 	s_7	s_8 
s_9	s_{10}	s_{11}	s_{12} 
s_{13} 	s_{14}	s_{15}	s_{16} 


獲得報酬の推移(Q学習)

659



価値関数マップ(Q学習)

660



s_1 	s_2	s_3	s_4
s_5	s_6 	s_7	s_8 
s_9	s_{10}	s_{11}	s_{12} 
s_{13} 	s_{14}	s_{15}	s_{16} 


獲得報酬の推移 (SARSA)

661



価値関数マップ(SARSA)


662



s_1 	s_2	s_3	s_4
s_5	s_6 	s_7	s_8 
s_9	s_{10}	s_{11}	s_{12} 
s_{13} 	s_{14}	s_{15}	s_{16} 


獲得報酬の推移 (Actor-Critic)

663



価値関数マップ (Actor-Critic)

664




s_1 	s_2	s_3	s_4
s_5	s_6 	s_7	s_8 
s_9	s_{10}	s_{11}	s_{12} 
s_{13} 	s_{14}	s_{15}	s_{16} 


獲得報酬の推移(比較)

665


モンテカルロ法




Q学習



SARSA




Actor-Critic




価値関数マップ(比較)

666


モンテカルロ法



Q学習



SARSA



Actor-Critic

