


2024年度
機械学習
第7週

担当教員 小林 邦和

- 第1回 ガイダンス:機械学習の概要
- 第2回 線形モデルによるクラス分類(線形サポートベクトルマシン)
- 第3回 非線形モデルによるクラス分類1(非線形サポートベクトルマシン)
- 第4回 非線形モデルによるクラス分類2(ニューラルネットワーク)
- 第5回 線形モデルによる回帰(線形サポートベクトル回帰)
- 第6回 非線形モデルによる回帰(非線形サポートベクトル回帰)
- 第7回 課題1(クラス分類と回帰)
- **第8回 線形モデルによる次元削減(主成分分析)**
- 第9回 非線形モデルによる次元削減(オートエンコーダ)
- 第10回 非階層的クラスタリング(k平均法)
- 第11回 階層的クラスタリング(凝集クラスタリング)
- 第12回 課題2(次元削減とクラスタリング)
- 第13回 強化学習(Q学習法)
- 第14回 課題3(強化学習)
- 第15回 期末試験

- 教師なし学習(復習)
- 次元削減
- 主成分分析(PCA)
- 演習(PCAによる次元削減)




- 目的

訓練集合が, 入力値のみで構成される問題を解く

- 適用例


- クラスタリング
- 次元圧縮



与えられたデータ群を分離する線を引く問題

人間は脳で教師なし学習している！

383






出典: 銅谷賢治「脳の各器官ごとの学習アルゴリズムによる機能分化」(1999年)

次元削減

- メモリ使用量の削減
- 計算コストの削減
- 可視化
- 次元の呪いの回避

3次元の空間までは振る舞いが想像できる
しかし、**4次元以上**の空間は想像できない

点	線分	正方形	立方体	正八胞体 (四次元超立方体)	
					
0	1	2	3	4	#次元

出典: Wikipedia

高次元空間の点の振る舞い(その1)

387

- **2次元空間**


一辺の長さが1の**単位正方形**

境界から0.001以内の存在確率:

$$p = 1 - (1 - 0.001 \times 2)^2$$

$$\doteq 0.003996$$

0.4%



- **10,000次元空間**

一辺の長さが1の**単位超立方体**

境界から0.001以内の存在確率:

$$p = 1 - (1 - 0.001 \times 2)^{10,000}$$

$$\doteq 0.999999999798$$

ほとんどの点が
境界付近に存在

高次元空間の点の振る舞い(その2)

388

- **2次元空間**

単位正方形内で無作為に選んだ2点の平均距離:
約0.52

- **10,000次元空間**

単位超正方形内で無作為に選んだ2点の平均距離:
約408.25



高次元空間: 広大

データセット: 疎

- 訓練データが互いに遠く離れている
- 予測の信頼性が低下する
- 過学習のリスクが高まる



次元の呪い

主成分分析(PCA)


主成分分析(PCA)

391


Principal Component Analysis

- 特徴

データの分散(散らばり具合)を維持した線形射影
→ 情報の損失が最小限



1. データの分散を**最大限維持**する軸を見つける
→ **第1主成分(C_1)**
2. C_1 軸に**直交した**次に分散を維持する軸を見つける
→ **第2主成分(C_2)**



データを低次元空間へ線形射影し、射影後のデータの分散を最大化



情報損失を最小限に抑えた次元削減方法

変数定義

- 特徴量ベクトル: $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$
- 射影ベクトル: $\mathbf{w} = (w_1, w_2, \dots, w_n)^T$
- 仮定: $\|\mathbf{w}\| = \mathbf{w}^T \mathbf{w} = 1$

1次元への次元
削減: $\mathbf{w}^T \mathbf{x}^p$

データ $\mathbf{x}^p$ の平均 $\bar{\mathbf{x}}$

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{p=1}^N \mathbf{x}^p$$

線形射影後のデータ $w^T x^p$ の平均 $\bar{y}$

$$\begin{aligned}\bar{y} &= \frac{1}{N} \sum_{p=1}^N w^T x^p \\ &= w^T \left(\frac{1}{N} \sum_{p=1}^N x^p \right) \\ &= w^T \bar{x}\end{aligned}$$

線形射影後のデータ $w^T x^p$ の分散 σ_y^2

$$\begin{aligned}\sigma_y^2 &= \frac{1}{N} \sum_{p=1}^N (y^p - \bar{y})^2 \\ &= \frac{1}{N} \sum_{p=1}^N (w^T x^p - w^T \bar{x})^2 \\ &= \frac{1}{N} \sum_{p=1}^N \{w^T (x^p - \bar{x})\}^2\end{aligned}$$

$$\begin{aligned} &= \frac{1}{N} \sum_{p=1}^N \mathbf{w}^T (\mathbf{x}^p - \bar{\mathbf{x}}) (\mathbf{x}^p - \bar{\mathbf{x}})^T \mathbf{w} \\ &= \mathbf{w}^T \left\{ \frac{1}{N} \sum_{p=1}^N (\mathbf{x}^p - \bar{\mathbf{x}}) (\mathbf{x}^p - \bar{\mathbf{x}})^T \right\} \mathbf{w} \\ &= \mathbf{w}^T S \mathbf{w} \end{aligned}$$

ここで, S は $\mathbf{x}^p$ の共分散行列(サイズ $n \times n$)

$$S = \frac{1}{N} \sum_{p=1}^N (\mathbf{x}^p - \bar{\mathbf{x}}) (\mathbf{x}^p - \bar{\mathbf{x}})^T$$

従って, 線形射影後のデータ $w^T x^p$ の分散 σ_y^2 を最大化するためには, 以下の最大値問題を解く必要がある

$$\begin{aligned} \max_w \quad & \frac{1}{2} w^T S w \\ \text{subject to} \quad & w^T w = 1 \end{aligned}$$

ラグランジュの未定乗数法を用いると

$$L(w, \lambda) = \frac{1}{2}w^T S w - \lambda (w^T w - 1)$$

ここで, λ はラグランジュの未定乗数

L を w で偏微分すると

$$\frac{\partial L}{\partial w} = Sw - \lambda w = \mathbf{0}$$

これより

$$Sw = \lambda w$$

ゆえに, λ は S の固有値と一致する

このとき, σ_y^2 は

$$w^T S w = w^T \lambda w = \lambda w^T w = \lambda$$

つまり, σ_y^2 ($w^T x^p$ の分散) の最大化は, S の固有値 λ の最大化と一致する

変数定義

d次元への次元削減

• 射影行列: $W = \left(\mathbf{w}_1^T, \dots, \mathbf{w}_j^T, \dots, \mathbf{w}_d^T \right)^T$

$$= \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{d1} & w_{d2} & \cdots & w_{dn} \end{pmatrix}$$

• 仮定: $\mathbf{w}_i^T \mathbf{w}_j = \begin{cases} 1 & (i = j) \\ 0 & (i \neq j) \end{cases}$

線形射影後のデータ $W^T x^p$ の平均 $\bar{y}$

$$\begin{aligned}\bar{y} &= \frac{1}{N} \sum_{p=1}^N W^T x^p \\ &= W^T \left(\frac{1}{N} \sum_{p=1}^N x^p \right) \\ &= W^T \bar{x}\end{aligned}$$

線形射影後のデータ $W^T x^p$ の分散 Σ_y

$$\begin{aligned}\Sigma_y &= \frac{1}{N} \sum_{p=1}^N \|W^T x^p - W^T \bar{x}\|^2 \\ &= \frac{1}{N} \sum_{p=1}^N W^T (x^p - \bar{x}) (x^p - \bar{x})^T W \\ &= W^T \left\{ \frac{1}{N} \sum_{p=1}^N (x^p - \bar{x}) (x^p - \bar{x})^T \right\} W \\ &= W^T S W\end{aligned}$$

D次元ベクトル

ここで, S は x^p の共分散行列 (サイズ $n \times n$)

$$S = \frac{1}{N} \sum_{p=1}^N (x^p - \bar{x})(x^p - \bar{x})^T$$

従って、線形射影後のデータ $W^T x^p$ の分散 Σ_y を最大化するためには、以下の最大値問題を解く必要がある

$$\max_W \frac{1}{2} W^T S W$$

$$\text{subject to } \mathbf{w}_i^T \mathbf{w}_j = \begin{cases} 1 & (i = j) \\ 0 & (i \neq j) \end{cases}$$

ラグランジュの未定乗数法を用いると

$$L(W, \lambda) = \frac{1}{2} W^T S W - \sum_{i=1}^d \lambda_i (w_i^T w_i - 1)$$

ここで, λ_i はラグランジュの未定乗数 ($i = 1 \sim d$)

$$\lambda = (\lambda_1, \lambda_2, \dots, \lambda_d)^T$$

固有値を対角成分にもつ行列 Λ と単位行列 I を用いると

$$\Lambda = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & 0 \\ & & \ddots & \\ 0 & & & \ddots \\ & & & & \lambda_d \end{pmatrix} \quad I = \begin{pmatrix} 1 & & & \\ & 1 & & 0 \\ & & \ddots & \\ 0 & & & \ddots \\ & & & & 1 \end{pmatrix}$$

L は次式で表される

$$L(W, \lambda) = \frac{1}{2} W^T S W - \Lambda (W^T W - I)$$

L を W で偏微分すると

$$\frac{\partial L}{\partial W} = SW - \Lambda W^T = SW - W\Lambda = \mathbf{0}$$

これより

$$SW = W\Lambda$$

ゆえに、 $\lambda_1 \sim \lambda_d$ は S の固有値と一致する

従って、行列 W の行成分 w_j^T ($i = 1 \sim d$)は、 S の固有ベクトルとなるので、互いに直交する

$$W = (w_1^T, \dots, w_j^T, \dots, w_d^T)^T$$

すなわち、 W は**直行行列**となる

このとき、 Σ_y は次式で表される

$$W^T S W = W^T W \Lambda = \Lambda$$

つまり、 $\Sigma_y(W^T x^p$ の分散)の最大化は、 **S の固有値 $\lambda_1 \sim \lambda_d$ の最大化**となる

変数定義

- 特徴量ベクトル: $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$
- 特徴量行列:

$$\mathbf{X} = (\mathbf{x}^1, \mathbf{x}^2, \dots, \mathbf{x}^p, \dots, \mathbf{x}^N)^T$$

$$= \begin{pmatrix} x_1^1 & x_2^1 & \cdots & x_n^1 \\ x_1^2 & x_2^2 & \cdots & x_n^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^p & x_2^p & \cdots & x_n^p \\ \vdots & \vdots & \ddots & \vdots \\ x_1^N & x_2^N & \cdots & x_n^N \end{pmatrix}$$

- 行列 V と U

$$V = (\boldsymbol{v}_1^T, \boldsymbol{v}_2^T, \dots, \boldsymbol{v}_N^T)^T$$

$$U = (\boldsymbol{u}_1^T, \boldsymbol{u}_2^T, \dots, \boldsymbol{u}_n^T)^T$$

ここで、ベクトル $\boldsymbol{v}_i$ と $\boldsymbol{u}_i$ は次式で表される

$$\boldsymbol{v}_i = (v_{i1}, v_{i2}, \dots, v_{in})^T$$

$$\boldsymbol{u}_i = (u_{i1}, u_{i2}, \dots, u_{iN})^T$$

特異値分解(PCA)[3/4]

413

ベクトル v_i は $\|Xv_i\|$ が最大値 σ_i をとる単位ベクトル($\|v_i\| = 1$)

ここで, $\sigma_i (i = 1 \sim N)$ には, 以下の関係があると仮定

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_N$$

またベクトル u_i は, 次式を満たす

$$u_i = \frac{1}{\sigma_i} X v_i$$

特異値分解(PCA)[4/4]

414

このとき, 行列 X は次式のように分解される(**特異値分解**)

$$X = U \Sigma V^T$$

ここで, $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_N)$

$$= \begin{pmatrix} \sigma_1 & & & & 0 \\ & \sigma_2 & & & \\ & & \ddots & & \\ 0 & & & \ddots & \\ & & & & \sigma_N \end{pmatrix}$$

特異値

アルゴリズム(PCA)

415

平均0, 分散1へ変換

1. 行列 X の標準化
2. 行列 X の共分散行列 S の計算
3. 行列 S の特異値分解

$$S = U \Sigma V^T$$

4. 主成分行列 V の第1～ d 列の抽出

$$V_d = (v_1^T, v_2^T, \dots, v_d^T)^T$$

5. 行列 X の次元削減(n 次元 $\rightarrow d$ 次元, $d \ll n$)

$$X_d = X V_d^T$$

S の特異値分解(PCA)[1/2]

416

$$\begin{aligned} S &= \frac{1}{N} \sum_{p=1}^N (\mathbf{x}^p - \bar{\mathbf{x}}) (\mathbf{x}^p - \bar{\mathbf{x}})^T \\ &= \frac{1}{N} \mathbf{Y}^T \mathbf{Y} \end{aligned}$$

ここで,

$$\mathbf{Y} = \left((\mathbf{x}^1 - \bar{\mathbf{x}})^T, (\mathbf{x}^2 - \bar{\mathbf{x}})^T, \dots, (\mathbf{x}^N - \bar{\mathbf{x}})^T \right)^T$$

S の特異値分解(PCA)[2/2]

417


$Y = U \Sigma V^T$ とおき, 特異値分解すると

$$\begin{aligned} S &= \frac{1}{N} (U \Sigma V^T) U \Sigma V^T \\ &= \frac{1}{N} V \Sigma U^T U \Sigma V^T \\ &= \frac{1}{N} V \Sigma \Sigma V^T \\ &= \frac{1}{N} V \operatorname{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_N^2) V^T \\ &= V \operatorname{diag}\left(\frac{\sigma_1^2}{N}, \frac{\sigma_2^2}{N}, \dots, \frac{\sigma_N^2}{N}\right) V^T \end{aligned}$$

演習

(主成分分析による次元削減)

- データセット: **アヤメデータ** (UCI MLリポジトリ)
- 問題設定: **3クラス分類** (Setosa, Versicolor, Verginica)
- インスタンス数: **150個** (50個/クラス)
- 特徴量数: **4**



- **4次元**の特徴量
- 散布図: **6個**の図
- ヒストグラム: **4個**の図
- PCA: **1個**の図(2次元)

データの標準化(コード)

421

平均0, 分散1へ変換

```
from sklearn.preprocessing import  
StandardScaler
```

標準化のクラス

```
scaler = StandardScaler()
```

```
scaler.fit(dataset.data)
```

モデルの学習

```
X_scaled = scaler.transform(dataset.data)
```


PCAの適用

散布図行列(アヤメ)

422


ヒストグラム

散布図



相関分析(アヤメ)

423



```
from sklearn.decomposition import PCA
```

Principal Component
Analysisのクラス

```
model = PCA(n_components=len(dataset.  
feature_names))
```

特徴量数

```
model.fit(X_scaled)
```


モデルの学習

```
X_reduced = model.transform(X_scaled)
```

主成分分析の実行

第1・第2主成分の散布図(アヤメ)

425



寄与率を大きさ順に棒グラフで表示

```
plt.bar([n for n in range(1, len(model.  
explained_variance_ratio_)+1)], model.  
explained_variance_ratio_)
```

```
plt.xlabel("Feature Variable")
```

```
plt.ylabel("Contribution Ratio")
```

```
plt.show()
```

累積寄与率(コード)

427

寄与率の抽出

```
ccr = model.explained_variance_ratio_
```


寄与率を大きさ順に足し合わせ、累積寄与率を計算

```
ccr = np.hstack([0,ccr.cumsum()])  
plt.plot(ccr)
```

```
plt.xlabel("Feature Variable")  
plt.ylabel("Cumulative Contribution Ratio")  
plt.grid()  
plt.show()
```

寄与率と累積寄与率(アヤメ)

428



特徴量の重要度(コード)

429

第1・第2主成分に対する重要度

```
plt.matshow(model.components_[:2])
```

カラーバーの表示

```
plt.colorbar()
```

```
plt.xticks(range(len(dataset.feature_names)),  
dataset.feature_names, rotation=60,  
ha='left')
```


```
plt.xlabel("Feature")
```

```
plt.ylabel("Principal components")
```

```
plt.show()
```

特徴量の重要度(アヤメ)

430



- データセット: **Cancerデータ** (UCI MLリポジトリ)
- 問題設定: 腫瘍データから良性・悪性の**2クラス分類**
- インスタンス数: **569個** (良性357個, 悪性212個)
- 特徴量数: **30**


- **30次元**の特徴量
- 散布図: **435個**の図!
- 相関係数(ヒートマップ): **435個**の図!
- ヒストグラム: **30個**の図
- PCA: **1個**の図(2次元)

散布図行列(Cancer)

433


ヒストグラム

散布図




ヒストグラム(Cancer)[1/3]

434




ヒストグラム(Cancer)[2/3]

435




ヒストグラム(Cancer)[3/3]

436



ヒストグラムからの知見(Cancer)


437



2クラスのヒストグラムの類似性が**高い(赤枠)**, **低い(青枠)**


相関分析(Cancer)

438




第1・第2主成分の散布図(Cancer)

439




寄与率と累積寄与率(Cancer)

440



特徴量の重要度(Cancer)

441



自主學習用課題

手書き数字(0~9)のデータセットに対して, 主成分分析で第2主成分まで求め, 散布図を描いてください. なおデータは以下の2行で読み込めます

```
from sklearn.datasets import load_digits  
dataset = load_digits()
```

自主学習用の課題なので提出不要