

2024年度
機械学習
第3週

担当教員 小林 邦和

- 第1回 ガイダンス:機械学習の概要
- 第2回 線形モデルによるクラス分類(線形サポートベクトルマシン)
- **第3回 非線形モデルによるクラス分類1(非線形サポートベクトルマシン)**
- 第4回 非線形モデルによるクラス分類2(ニューラルネットワーク)
- 第5回 線形モデルによる回帰(線形サポートベクトル回帰)
- 第6回 非線形モデルによる回帰(非線形サポートベクトル回帰)
- 第7回 課題1(クラス分類と回帰)
- 第8回 線形モデルによる次元削減(主成分分析)
- 第9回 非線形モデルによる次元削減(オートエンコーダ)
- 第10回 非階層的クラスタリング(k平均法)
- 第11回 階層的クラスタリング(凝集クラスタリング)
- 第12回 課題2(次元削減とクラスタリング)
- 第13回 強化学習(Q学習法)
- 第14回 課題3(強化学習)
- 第15回 期末試験


- 線形モデルの限界
- 非線形SVM
- 演習(非線形SVMによるクラス分類)

線形SVMの限界

線形SVM(ハードマージン)の概念


150

Support Vector Machine





線形SVM(ソフトマージン)の概念

151



線形SVMの限界(1次元空間)

152





- 左図: ソフトマージンでも対応不可

非線形特徴量

- 右図: 新しい特徴量($x_2 = x_1^2$)の追加で特徴量次元を上げると(1次元→2次元), 線形分離可能となる

線形SVMの限界(2次元空間)

153




- 左図: 線形分離不可の2次元特徴量

非線形特徴量

- 右図: 新しい特徴量($\text{feature}_2 = \text{feature}_1^2$)の追加により線形分離可能

非線形SVM


2次元特徴量




多項式特徴量:

$$\hat{y} = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \alpha_3 x_1^2 + \alpha_4 x_2^2 + \alpha_5 x_1 x_2 \\ + \cdots + \alpha_{n-1} x_1^n + \alpha_n x_2^n$$

非線形な決定境界
($n = 3$ の場合)




距離特徴量



目印 $x_1^1 = -2$


目印 $x_1^2 = 0.5$

$\gamma = 0.3$ の場合



左図: 特徴量 x_1 の2つの目印からの距離の特徴量 x_2, x_3
右図: 新しい特徴量 $x_2 = e^{-\gamma(x_2 - x_1^1)^2}$ $x_3 = e^{-\gamma(x_3 - x_1^2)^2}$

多項式カーネル: $K(x, x^p) = (x^T x^p + r)^d$



3次多項式カーネル

10次多項式カーネル

C : L2正則化項の係数(ハイパーパラメータ)

非線形変換の適用(その2)


159

ガウスカーネル: $K(x, x^p) = \exp(-\gamma \|x - x^p\|^2)$

モデル複雑度:大

モデル複雑度:小

ガウス分布:平坦



ガウス分布:急峻

1. 非線形特徴量の導入

特徴数を増加させ, 特徴空間の次元を上げる

→ 高次元空間で線形分離

2. 非線形変換の適用

特徴数は増加させず, 特徴量に非線形変換を適用

→ 計算コスト増

→ カーネルトリックで回避可

マージン最大化(非線形SVM)

161

制約条件付き最適化:

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$\text{subject to } y^p (w^T \phi(x^p) + b) \geq 1 \quad (p = 1 \sim N)$$

線形SVMとの
相違

制約条件付き最適化問題:

$$L(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{p=1}^N a_p \left(y^p \left(\mathbf{w}^T \phi(\mathbf{x}^p) + b \right) - 1 \right)$$

関数 L の最小化問題

線形SVMとの
相違

ラグランジュ未定乗数法の制約条件($p = 1 \sim N$)

$$\begin{cases} a_p \geq 0 \\ y^p (w^T \phi(x^p) + b) - 1 \geq 0 \\ a_p \{y^p (w^T \phi(x^p) + b) - 1\} = 0 \end{cases}$$

線形SVMとの
相違

ラグランジュ関数 L を w, b で各々偏微分し, ゼロとおくと,

$$\frac{\partial L}{\partial w} = w - \sum_{p=1}^N a_p y^p \phi(x^p) = \mathbf{0}$$

$$\frac{\partial L}{\partial b} = - \sum_{p=1}^N a_p y^p = 0$$

従って,

$$\mathbf{w} = \sum_{p=1}^N a_p y^p \phi(\mathbf{x}^p)$$

$$\sum_{p=1}^N a_p y^p = 0$$

これら関数 L へ代入すると,

$$\begin{aligned} L(\mathbf{w}, b, \mathbf{a}) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{p=1}^N a_p \left(y^p \left(\mathbf{w}^T \phi(\mathbf{x}^p) + b \right) - 1 \right) \\ &= -\frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N a_p a_q y^p y^q \phi(\mathbf{x}^p)^T \phi(\mathbf{x}^q) \\ &\quad - \sum_{p=1}^N a_p y^p b + \sum_{p=1}^N a_p \\ &= -\frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N a_p a_q y^p y^q \phi(\mathbf{x}^p)^T \phi(\mathbf{x}^q) + \sum_{p=1}^N a_p \end{aligned}$$

線形SVMとの
相違

最適化(非線形SVM)[4/4]

167

ゆえに, 関数 L の最小化問題は, 次式となる

線形SVMとの
相違

$$\min_a \left(-\frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N a_p a_q y^p y^q \phi(\mathbf{x}^p)^T \phi(\mathbf{x}^q) + \sum_{p=1}^N a_p \right)$$

$$\text{subject to } \sum_{p=1}^N a_p y^p = 0, \quad a_p \geq 0 \quad (p = 1 \sim N)$$

最適解:

$$\mathbf{w} = \sum_{p=1}^N a_p y^p \phi(\mathbf{x}^p)$$

線形SVMとの
相違

$$b = \frac{1}{N} \sum_{p=1}^N \left(y^p - \sum_{q=1}^N a_q y^q \phi(\mathbf{x}^q) \phi(\mathbf{x}^p) \right)$$

- 線形SVMに比べ**計算コスト増**
 1. 特徴量ベクトル x の**非線形変換** $\phi(x)$
 2. **高次元ベクトル** $\phi(x^q)$ と $\phi(x^p)$ の内積
- **カーネルトリック**

非線形変換や高次元の内積計算の回避
→ 計算コスト増は最小限

決定関数:

$$h(\mathbf{x}; \mathbf{w}, b) = \mathbf{w}^T \phi(\mathbf{x}) + b$$

$\mathbf{w}$ の最適解を代入すると,

$$\begin{aligned} h(\mathbf{x}^p; \mathbf{w}, b) &= \sum_{q=1}^N a_q y^q \phi(\mathbf{x}^q)^T \phi(\mathbf{x}^p) + b \\ &= \sum_{q=1}^N a_q y^q \boxed{K(\mathbf{x}^q, \mathbf{x}^p)} + b \end{aligned}$$

カーネル関数

最適化問題:

$$\min_{\mathbf{w}, b} L(\mathbf{w}, b, \mathbf{a})$$

但し,

$$\begin{aligned} L(\mathbf{w}, b, \mathbf{a}) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{p=1}^N a_p \left(y^p \left(\mathbf{w}^T \phi(\mathbf{x}^p) + b \right) - 1 \right) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{p=1}^N a_p \left(y^p \left(\sum_{q=1}^N a_q y^q \phi(\mathbf{x}^q)^T \phi(\mathbf{x}^p) + b \right) - 1 \right) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{p=1}^N a_p \left(y^p \left(\sum_{q=1}^N a_q y^q \boxed{K(\mathbf{x}^q, \mathbf{x}^p)} + b \right) - 1 \right) \end{aligned}$$

カーネル関数

多項式カーネル:

$$K(\mathbf{x}, \mathbf{y}) = (\gamma \mathbf{x}^T \mathbf{y} + r)^d$$

ガウスカーネル:

$$K(\mathbf{x}, \mathbf{y}) = \exp(-\gamma \|\mathbf{x} - \mathbf{y}\|^2)$$

シグモイドカーネル:

$$K(\mathbf{x}, \mathbf{y}) = \tanh(\gamma \mathbf{x}^T \mathbf{y} + r)$$

2次元多項式カーネルの例

173

2つのベクトル $\mathbf{x} = (x_1, x_2)^T$ と $\mathbf{y} = (y_1, y_2)^T$

非線形変換: $\phi(\mathbf{x}) = \phi((x_1, x_2)^T)$

$$= (x_1^2, \sqrt{2}x_1x_2, x_2^2)^T$$

カーネル関数: $K(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x})^T \phi(\mathbf{y})$

カーネルトリック

非線形変換した高次元ベクトル $\phi(\mathbf{x})$ と $\phi(\mathbf{y})$ の内積計算が、変換前のベクトル $\mathbf{x}$ と $\mathbf{y}$ の内積の二乗計算で置換できる!

$$= (x_1^2, \sqrt{2}x_1x_2, x_2^2) (y_1^2, \sqrt{2}y_1y_2, y_2^2)^T$$

$$= x_1^2y_1^2 + 2x_1y_1x_2y_2 + x_2^2y_2^2$$

$$= (x_1y_1 + x_2y_2)^2$$

$$= ((x_1, x_2) (y_1, y_2)^T)^2$$

$$= (\mathbf{x}^T \mathbf{y})^2$$


演習

(非線形SVMによるクラス分類)

データの準備(ガウス分布状2次元データ)

175


- **make_blobs**



データの準備(三日月状2次元データ)

176

- **make_moons**



引数

- `n_samples`: データの個数
- `noise`: ガウスノイズの標準偏差
- `random_state`: 乱数生成のシード値
※同じ値の設定で再現性の確保


戻り値

- `X`: 入力データ(特徴量, $n_samples \times 2$)
- `y`: 出力データ(クラス番号, $n_samples$)

データの準備(同心円状2次元データ)

178

- **make_circles**



引数

- `n_samples`: データの個数
- `noise`: ガウスノイズの標準偏差
- `random_state`: 乱数生成のシード値
※同じ値の設定で再現性の確保

戻り値

- `X`: 入力データ(特徴量, $n_samples \times 2$)
- `y`: 出力データ(クラス番号, $n_samples$)

非線形SVMの学習(コード)

180

```
from sklearn.svm import SVC
```

SVMのクラス

カーネル関数の指定

```
model = SVC(kernel='rbf', C=100)
```

動径基底関数: 'rbf'
多項式関数: 'poly'
シグモイド関数: 'sigmoid'

```
model.fit(X_train, y_train)
```

モデルの学習

非線形SVMの結果(ガウス分布状2次元データ)


181

カーネル	正解率(%)	混同行列
RBF	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$
多項式	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$
シグモイド	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$


非線形SVMの結果(ガウス分布状2次元データ)

182


- 決定境界



RBF



多項式



シグモイド

線形/非線形SVMの結果(ガウス分布状2次元データ)


183

タイプ	正解率(%)	混同行列
線形/ハードマージン	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$
線形/ソフトマージン	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$
非線形/RBF	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$
非線形/多項式	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$
非線形/シグモイド	98.7	$\begin{bmatrix} 40 & 0 \\ 1 & 34 \end{bmatrix}$


線形/非線形SVMの結果(ガウス分布状2次元データ)

184


• 決定境界




線形/ハードマージン




線形/ソフトマージン



非線形/RBF



非線形/多項式



非線形/シグモイド

非線形SVMの結果(三日月状データ)


185

カーネル	正解率(%)	混同行列
RBF	98.7	$\begin{bmatrix} 41 & 0 \\ 1 & 33 \end{bmatrix}$
多項式	90.7	$\begin{bmatrix} 35 & 6 \\ 1 & 33 \end{bmatrix}$
シグモイド	64.0	$\begin{bmatrix} 25 & 16 \\ 11 & 23 \end{bmatrix}$


非線形SVMの結果(三日月状データ)

186


- 決定境界



RBF



多項式



シグモイド

線形/非線形SVMの結果(三日月状データ)


187

タイプ	正解率(%)	混同行列
線形/ハードマージン	88.0	$\begin{bmatrix} 38 & 3 \\ 6 & 28 \end{bmatrix}$
線形/ソフトマージン	86.7	$\begin{bmatrix} 37 & 4 \\ 6 & 28 \end{bmatrix}$
非線形/RBF	98.7	$\begin{bmatrix} 41 & 0 \\ 1 & 33 \end{bmatrix}$
非線形/多項式	90.7	$\begin{bmatrix} 35 & 6 \\ 1 & 33 \end{bmatrix}$
非線形/シグモイド	64.0	$\begin{bmatrix} 25 & 16 \\ 11 & 23 \end{bmatrix}$


線形/非線形SVMの結果(三日月状データ)

188


• 決定境界




線形/ハードマージン




線形/ソフトマージン



非線形/RBF



非線形/多項式



非線形/シグモイド

非線形SVMの結果(同心円状データ)


189

カーネル	正解率(%)	混同行列
RBF	81.3	$\begin{bmatrix} 36 & 5 \\ 9 & 25 \end{bmatrix}$
多項式	56.0	$\begin{bmatrix} 11 & 30 \\ 3 & 31 \end{bmatrix}$
シグモイド	49.3	$\begin{bmatrix} 16 & 25 \\ 13 & 21 \end{bmatrix}$


非線形SVMの結果(同心円状データ)

190


- 決定境界



RBF



多項式



シグモイド

線形/非線形SVMの結果(同心円状データ)


191

タイプ	正解率(%)	混同行列
線形/ハードマージン	45.3	$\begin{bmatrix} 0 & 41 \\ 0 & 34 \end{bmatrix}$
線形/ソフトマージン	45.3	$\begin{bmatrix} 0 & 41 \\ 0 & 34 \end{bmatrix}$
非線形/RBF	81.3	$\begin{bmatrix} 36 & 5 \\ 9 & 25 \end{bmatrix}$
非線形/多項式	56.0	$\begin{bmatrix} 11 & 30 \\ 3 & 31 \end{bmatrix}$
非線形/シグモイド	49.3	$\begin{bmatrix} 16 & 25 \\ 13 & 21 \end{bmatrix}$


線形/非線形SVMの結果(同心円状データ)

192


- 決定境界




線形/ハードマージン




線形/ソフトマージン



非線形/RBF



非線形/多項式



非線形/シグモイド