

2024年度
機械学習
第5週

担当教員 小林 邦和

- 第1回 ガイダンス:機械学習の概要
- 第2回 線形モデルによるクラス分類(線形サポートベクトルマシン)
- 第3回 非線形モデルによるクラス分類1(非線形サポートベクトルマシン)
- 第4回 非線形モデルによるクラス分類2(ニューラルネットワーク)
- 第5回 線形モデルによる回帰(線形サポートベクトル回帰)
- 第6回 非線形モデルによる回帰(非線形サポートベクトル回帰)
- 第7回 課題1(クラス分類と回帰)
- 第8回 線形モデルによる次元削減(主成分分析)
- 第9回 非線形モデルによる次元削減(オートエンコーダ)
- 第10回 非階層的クラスタリング(k平均法)
- 第11回 階層的クラスタリング(凝集クラスタリング)
- 第12回 課題2(次元削減とクラスタリング)
- 第13回 強化学習(Q学習法)
- 第14回 課題3(強化学習)
- 第15回 期末試験

- 線形回帰モデル
- SVMの回帰への適用  Support Vector Regression
- ハードマージン線形SVR
- ソフトマージン線形SVR
- 非線形SVR
- MLP回帰器
- 演習(線形SVMによる回帰)

線形モデルの回帰への適用

予測式: $\hat{y} = h(\mathbf{x}; \mathbf{w}, b)$

$$= \mathbf{w}^T \mathbf{x} + b$$

$$= w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b$$

決定関数: $h(\mathbf{x}; \mathbf{w}, b)$

パラメータベクトル: $\mathbf{w} = (w_1, w_2, \cdots, w_n)^T$

特徴量ベクトル: $\mathbf{x} = (x_1, x_2, \cdots, x_n)^T$


バイアス成分(スカラー): b

$$\begin{aligned}\text{予測式: } \hat{y} &= h(\mathbf{x}; \mathbf{w}, b) \\ &= \mathbf{w}^T \mathbf{x} + b \\ &= w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b\end{aligned}$$

予測 $\hat{y}$ は連続値なので, そのまま回帰へ適用可
※2クラス分類は離散化が必要

1次元回帰予測のデータセット

255



データ数: 60 (横軸: 特徴量, 縦軸: 出力値)

線形回帰モデル(最小二乗法)

256

予測式: $\hat{y} = h(\mathbf{x}; \mathbf{w}, b)$

$$= \mathbf{w}^T \mathbf{x} + b$$

損失関数(2乗誤差):

$$E(\mathbf{w}, b) = \frac{1}{2} \sum_{p=1}^N (y^p - \hat{y}^p)^2$$
$$= \frac{1}{2} \sum_{p=1}^N \left\{ y^p - (\mathbf{w}^T \mathbf{x}^p + b) \right\}^2$$

N : 訓練データ数

線形回帰モデル(最小二乗法)

257

予測式: $\hat{y} = h(\mathbf{x}; \mathbf{w}, b)$
 $= \mathbf{w}^T \mathbf{x} + b$


二乗和誤差の最小化:

$$\begin{aligned}\hat{\mathbf{w}}, \hat{b} &= \arg \min_{\mathbf{w}, b} \sum_{p=1}^N (y^p - \hat{y}^p)^2 \\ &= \arg \min_{\mathbf{w}, b} \sum_{p=1}^N (y^p - h(\mathbf{x}^p; \mathbf{w}, b))^2\end{aligned}$$

N : 訓練データ数

線形回帰モデルの結果

258



$$\text{予測式 } \hat{y} = 0.393906x - 0.031804$$

SVMの回帰への適用

分類と回帰における目的の違い

260

サポートベクトルマシン(SVM)

分類の目的

1. **マージン最大化** (マージン最大となる決定境界線を引く)
2. **マージン違反最小化** (誤分類やマージン違反は最小限)


サポートベクトル回帰(SVR)

回帰の目的

1. **マージン最大化** (マージン最大となる回帰線を引く)
2. **マージン違反最大化** (マージン違反は最大限許容)

SVM分類器の目的(マージン最大化)


261



インスタンスが最小限含まれる最も幅広の道を境界に通す

SVM回帰の目的(マージン最大化)


262



インスタンスが最大限含まれる最も幅広の道を境界に通す

回帰用データ(その1)

263



データ生成式:

$$y = 3x_1 + 4 + \sigma$$

$$\sigma \sim N(0, 1)$$

$$x_1 \in [0.0, 2.0]$$

線形SVR



264

Support Vector Regression

マージンの中に入るインスタンス数の最大化

$\varepsilon = 1.5$


$\varepsilon = 0.5$



左図は右図より、マージンが大きく、マージン内のインスタンス数も多い

回帰用データ(その2)

265




データ生成式:

$$y = \frac{1}{10} (5x_1^2 + x_1 + 2 + \sigma)$$

$$\sigma \sim N(0, 1)$$

$$x_1 \in [-1.0, 1.0]$$

2次多項式カーネル



左図は右図より, L2正則化項の係数が大きい


損失関数(線形SVR)[1/2]

267

$$E(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{p=1}^N h(y^p - \hat{y}^p)$$

但し, h は誤差関数, C は係数

$$h(e) = \max(0, |y^p - \hat{y}^p| - \varepsilon)$$



損失関数(線形SVR)[2/2]

268

$$\begin{aligned} E(\mathbf{w}, b) &= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{p=1}^N h(y^p - \hat{y}^p) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{p=1}^N \max(0, |y^p - \hat{y}^p| - \varepsilon) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 + C \left\{ \sum_{p=1}^N \max(0, (y^p - \hat{y}^p) - \varepsilon) \right. \\ &\quad \left. + \sum_{p=1}^N \max(0, (\hat{y}^p - y^p) - \varepsilon) \right\} \end{aligned}$$

マージン最大化(線形SVR)

269

制約条件付き最適化:

変数 w, b, ξ^+, ξ^-
に関する最小化

$$\min_{w, b, \xi^+, \xi^-} \frac{1}{2} \|w\|^2 + C \sum_{p=1}^N (\xi_p^+ + \xi_p^-)$$

$$\text{subject to } \xi_p^+ \geq y^p - w^T x_p - b - \varepsilon, \xi_p^+ \geq 0 \quad (p = 1 \sim N)$$

$$\xi_p^- \geq w^T x_p + b - y^p - \varepsilon, \xi_p^- \geq 0 \quad (p = 1 \sim N)$$

ここで,

$$\xi^+ = (\xi_1^+, \xi_2^+, \dots, \xi_N^+)^T$$

$$\xi^- = (\xi_1^-, \xi_2^-, \dots, \xi_N^-)^T$$

定式化(線形SVR)[1/2]

270

制約条件付き最適化問題: 関数 L の最小化問題

$$L(\mathbf{w}, b, \xi^+, \xi^-, a^+, a^-, \eta^+, \eta^-)$$

$$= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{p=1}^N (\xi_p^+ + \xi_p^-)$$

$$- \sum_{p=1}^N a_p^+ \left\{ \xi_p^+ - (y^p - \mathbf{w}^T \mathbf{x}^p - b) + \varepsilon \right\} - \sum_{p=1}^N \eta_p^+ \xi_p^+$$

$$- \sum_{p=1}^N a_p^- \left\{ \xi_p^- - (\mathbf{w}^T \mathbf{x}^p - b - y^p) + \varepsilon \right\} - \sum_{p=1}^N \eta_p^- \xi_p^-$$

ラグランジュ乗数ベクトル:

$$\mathbf{a}^+ = (a_1^+, a_2^+, \dots, a_N^+)^T$$

$$\mathbf{a}^- = (a_1^-, a_2^-, \dots, a_N^-)^T$$

$$\boldsymbol{\eta}^+ = (\eta_1^+, \eta_2^+, \dots, \eta_N^+)^T$$

$$\boldsymbol{\eta}^- = (\eta_1^-, \eta_2^-, \dots, \eta_N^-)^T$$

ラグランジュ未定乗数法の制約条件($p = 1 \sim N$)

$$\left\{ \begin{array}{l} a_p^+ \left\{ \xi_p^+ - \left(y^p - \mathbf{w}^T \mathbf{x}_p - b \right) + \varepsilon \right\} = 0 \\ a_p^- \left\{ \xi_p^- - \left(\mathbf{w}^T \mathbf{x}_p - b - y^p \right) + \varepsilon \right\} = 0 \\ \left(C - \eta_p^+ \right) \xi_p^+ = 0 \\ \left(C - \eta_p^- \right) \xi_p^- = 0 \end{array} \right.$$

双対問題(線形SVR)[1/5]

273

ラグランジュ関数 L を w , b , ξ_p^+ , ξ_p^- で各々偏微分し, ゼロとおくと,

$$\frac{\partial L}{\partial w} = w - \sum_{p=1}^N a_p^+ \mathbf{x}^p + \sum_{p=1}^N a_p^- \mathbf{x}^p = \mathbf{0}$$

$$\frac{\partial L}{\partial b} = - \sum_{p=1}^N a_p^+ + \sum_{p=1}^N a_p^- = 0$$

$$\frac{\partial L}{\partial \xi_p^+} = C - a_p^+ - \eta_p^+ = 0 \quad (p = 1 \sim N)$$

$$\frac{\partial L}{\partial \xi_p^-} = C - a_p^- - \eta_p^- = 0 \quad (p = 1 \sim N)$$

従って,

$$\mathbf{w} = \sum_{p=1}^N (a_p^+ - a_p^-) \mathbf{x}^p$$

$$\sum_{p=1}^N a_p^+ = \sum_{p=1}^N a_p^-$$

$$\eta_p^+ = C - a_p^+ \quad (p = 1 \sim N)$$

$$\eta_p^- = C - a_p^- \quad (p = 1 \sim N)$$

これら関数 L へ代入すると,

$$\begin{aligned} L(\mathbf{w}, b, \xi^+, \xi^-, \mathbf{a}^+, \mathbf{a}^-, \eta^+, \eta^-) \\ = \frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N (a_p^+ - a_p^-) (a_q^+ - a_q^-) (\mathbf{x}^p)^T \mathbf{x}^q + C \sum_{p=1}^N (\xi_p^+ + \xi_p^-) \\ - \sum_{p=1}^N a_p^+ \left\{ \xi_p^+ - \left(y^p - \sum_{q=1}^N (a_q^+ - a_q^-) (\mathbf{x}_q)^T \mathbf{x}^p - b \right) + \varepsilon \right\} - \sum_{p=1}^N (C - a_p^+) \xi_p^+ \\ - \sum_{p=1}^N a_p^- \left\{ \xi_p^- - \left(\sum_{q=1}^N (a_q^+ - a_q^-) (\mathbf{x}_q)^T \mathbf{x}^p + b - y^p \right) + \varepsilon \right\} - \sum_{p=1}^N (C - a_p^-) \xi_p^- \end{aligned}$$

従って,

$$L(\mathbf{w}, b, \xi^+, \xi^-, \mathbf{a}^+, \mathbf{a}^-, \eta^+, \eta^-)$$

$$\begin{aligned} &= -\frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N (a_p^+ - a_p^-) (a_q^+ - a_q^-) (\mathbf{x}^p)^T \mathbf{x}^q \\ &\quad + \sum_{p=1}^N (a_p^+ - a_p^-) y^p - \sum_{p=1}^N (a_p^+ + a_p^-) \varepsilon \end{aligned}$$

ゆえに, 関数 L の双対問題は次式となる

変数 a^+, a^- に関する最小化

$$\min_{a^+, a^-} \left\{ -\frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N (a_p^+ - a_p^-) (a_q^+ - a_q^-) (\mathbf{x}_p)^T \mathbf{x}_q \right. \\ \left. + \sum_{p=1}^N (a_p^+ - a_p^-) y^p - \sum_{p=1}^N (a_p^+ + a_p^-) \varepsilon \right\}$$

$$\text{subject to } \sum_{p=1}^N a_p^+ = \sum_{p=1}^N a_p^-,$$

$$0 \leq a_p^+ \leq C, \quad 0 \leq a_p^- \leq C \quad (p = 1 \sim N)$$

マージン最大化(非線形SVR)

278

制約条件付き最適化:

$$\min_{w, b, \xi^+, \xi^-} \frac{1}{2} \|w\|^2 + C \sum_{p=1}^N (\xi_p^+ + \xi_p^-)$$

線形SVRとの
相違

$$\text{subject to } \xi_p^+ \geq y^p - w^T \phi(x_p) - b - \varepsilon, \xi_p^+ \geq 0 \quad (p = 1 \sim N)$$

$$\xi_p^- \geq w^T \phi(x_p) + b - y^p - \varepsilon, \xi_p^- \geq 0 \quad (p = 1 \sim N)$$

ここで,

$$\xi^+ = (\xi_1^+, \xi_2^+, \dots, \xi_N^+)^T$$

$$\xi^- = (\xi_1^-, \xi_2^-, \dots, \xi_N^-)^T$$

定式化(非線形SVR)[1/2]

279

制約条件付き最適化問題: 関数 L の最小化問題

$$L(\mathbf{w}, b, \xi^+, \xi^-, a^+, a^-, \eta^+, \eta^-)$$

$$= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{p=1}^N (\xi_p^+ + \xi_p^-)$$

線形SVRとの
相違

$$\begin{aligned} & - \sum_{p=1}^N a_p^+ \left\{ \xi_p^+ - \left(y^p - \mathbf{w}^T \phi(\mathbf{x}_p) - b \right) + \varepsilon \right\} - \sum_{p=1}^N \eta_p^+ \xi_p^+ \\ & - \sum_{p=1}^N a_p^- \left\{ \xi_p^- - \left(\mathbf{w}^T \phi(\mathbf{x}_p) - b - y^p \right) + \varepsilon \right\} - \sum_{p=1}^N \eta_p^- \xi_p^- \end{aligned}$$

ラグランジュ乗数ベクトル:

$$\mathbf{a}^+ = (a_1^+, a_2^+, \dots, a_N^+)^T$$

$$\mathbf{a}^- = (a_1^-, a_2^-, \dots, a_N^-)^T$$

$$\boldsymbol{\eta}^+ = (\eta_1^+, \eta_2^+, \dots, \eta_N^+)^T$$

$$\boldsymbol{\eta}^- = (\eta_1^-, \eta_2^-, \dots, \eta_N^-)^T$$

ラグランジュ未定乗数法の制約条件($p = 1 \sim N$)

$$\left\{ \begin{array}{l} a_p^+ \left\{ \xi_p^+ - \left(y^p - \mathbf{w}^T \phi(\mathbf{x}_p) - b \right) + \varepsilon \right\} = 0 \\ a_p^- \left\{ \xi_p^- - \left(\mathbf{w}^T \phi(\mathbf{x}_p) - b - y^p \right) + \varepsilon \right\} = 0 \\ \left(C - \eta_p^+ \right) \xi_p^+ = 0 \\ \left(C - \eta_p^- \right) \xi_p^- = 0 \end{array} \right.$$

線形SVRとの
相違

線形SVRと同様の導出により, 関数 L の双対問題は, 次式となる

線形SVRとの相違

$$\begin{aligned} \min_{a^+, a^-} & \left\{ -\frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N (a_p^+ - a_p^-) (a_q^+ - a_q^-) \phi(\mathbf{x}_p)^T \phi(\mathbf{x}_q) \right. \\ & \left. + \sum_{p=1}^N (a_p^+ - a_p^-) y^p - \sum_{p=1}^N (a_p^+ + a_p^-) \varepsilon \right\} \\ \text{subject to } & \sum_{p=1}^N a_p^+ = \sum_{p=1}^N a_p^-, \\ & 0 \leq a_p^+ \leq C, \quad 0 \leq a_p^- \leq C \quad (p = 1 \sim N) \end{aligned}$$


MLPの回帰への適用

MLPによる回帰

284

Multi-Layer Perceptron

- 入力特徴量(説明変数)により出力値(目的変数)を予測する



回帰の評価

- 決定係数 R^2
- 平均平方二乗誤差(RMSE)
- 平均絶対誤差(MAE)

決定係数 R^2

287

- 定義式

$$R^2 = 1 - \frac{\sum_{p=1}^N (y^p - \hat{y}^p)^2}{\sum_{p=1}^N (y^p - \bar{y})^2}$$

モデルでは説明できない予測値のばらつき

決定係数	精度
$0.8 \leq R^2$	非常に良い
$0.5 \leq R^2 < 0.8$	やや良い
$R^2 < 0.5$	悪い

平均値では説明できない予測値のばらつき

- 特徴

モデルがデータをどの程度説明できているか

回帰モデルへのあてはまりの良さで評価
予測と正解が近いほど1へ、離れるほど0へ近づく

平均平方二乗誤差 (RMSE)

288

Root Mean Square Error

- 定義式

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{p=1}^N (y^p - \hat{y}^p)^2}$$

予測と正解の二乗誤差

- 特徴

予測と正解の誤差で評価

外れ値の影響を受けやすい

特徴量とのスケール(単位)が同一

平均絶対誤差 (MAE)

289

Mean Absolute Error

- 定義式

$$\text{MAE} = \frac{1}{N} \sum_{p=1}^N |y^p - \hat{y}^p|$$

予測と正解の絶対誤差

- 特徴

予測と正解の誤差で評価

予測と正解が近いほど小さくなるが、外れ値の影響は受けにくい


演習

(各種モデルによる回帰)

データの準備(1次元回帰データ)

291

make_regression



引数

- `n_samples`: データの個数
- `n_features`: 特徴量の数
- `noise`: ガウスノイズの標準偏差
- `random_state`: 乱数生成のシード値

戻り値

- `X`: 入力データ (特徴量, $n_samples \times 2$)
- `y`: 出力データ (クラス番号, $n_samples$)

make_regressionの使い方(コード) 293

```
from sklearn.datasets import make_regression  
import pandas as pd
```

入力 出力

サンプル数100個

```
X, y = make_regression(n_samples=100,  
n_features=1, noise=10, random_state=3)
```

特徴量1次元

ノイズの標準偏差
(散らばり具合)

乱数シード値

```
df = pd.DataFrame(X)
```

データフレーム化

```
df["Y"] = y
```

Y指定で出力値の追加

```
df.head()
```

先頭5行の表示

先頭5行のデータ

0番目サンプル
の入力

0番目サンプル
 の出力

	X	Y
0	0.150617	8.013899
1	-0.888657	-25.792846
2	-1.860890	-79.826582
3	0.152946	-3.008826
4	0.899338	19.862157

データセットの描画(コード)

295

Notebook形式
の場合は必要

```
%matplotlib inline
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

グラフの描画

横軸にX, 縦軸にYを指定

```
sns.scatterplot(x="X", y="Y", color="b", data=df)
```

グラフ見出し

```
plt.title("Dataset")
```


グリッドの設定


```
plt.grid()
```

グラフの描画


```
plt.show()
```

回帰用データセット





左図: ノイズが大きな場合
(noise=30)




右図: 特徴量2次元の場合
(n_features=2)

データセットの分割(コード)

298

```
from sklearn.model_selection import train_test_split  
X_train, X_test, y_train, y_test = train_test_split(X, y,  
random_state=0)
```



訓練データ(O印)とテストデータ(X印)

引数

- test_size: テストデータのサイズ指定 (0~1.0)
- train_size: 訓練データのサイズ指定 (0~1.0)
- random_state: 乱数生成のシード値

戻り値

- X_train: 訓練用入力データ
- X_test: テスト用入力データ
- y_train: 訓練用出力データ
- y_test: テスト用出力データ

線形回帰モデルの学習(コード)

300

```
from sklearn.linear_model import  
LinearRegression
```

線形回帰モデルのクラス

```
model = LinearRegression()
```

```
model.fit(X_train, y_train)
```

モデルの学習

線形SVRの学習(コード)

301

```
from sklearn.svm import SVR
```

Support **V**ector
Regressionのクラス

線形SVRの指定

```
model = SVR(kernel='linear', C=100)
```

```
model.fit(X_train, y_train)
```

モデルの学習

正則化係数
C:大→ハードマージン型
C:小→ソフトマージン型

非線形SVRの学習(コード)

302

```
from sklearn.svm import SVR
```

カーネル関数の指定

```
model = SVR(kernel='rbf', C=100)
```

動径基底関数: 'rbf'
多項式関数: 'poly'
シグモイド関数: 'sigmoid'

```
model.fit(X_train, y_train)
```

モデルの学習

MLPの学習(コード)

303

```
from sklearn.neural_network import  
MLPRegressor
```

MLP回帰器のクラス

中間層の層数とユニット数
の指定(タプル)

```
model = MLPRegressor(hidden_layer_sizes=  
(10,), activation='logistic')
```

活性化関数の指定

シグモイド関数: 'logistic'
双曲線正接関数: 'tanh'
正規化線形関数: 'relu'

```
model.fit(X_train, y_train)
```

モデルの学習

テストデータによる評価(コード)

304

決定係数の計算

```
from sklearn.metrics import r2_score  
score = r2_score(y_test, pred_test)  
print("決定係数 = {0:6.3f}%".format(score))
```

平均絶対誤差(MAE)の計算

```
from sklearn.metrics import mean_absolute_error  
score = mean_absolute_error(y_test, pred_test)  
print("MAE = {0:6.2f}".format(score))
```

平均平方二乗誤差(RMSE)

```
from sklearn.metrics import mean_squared_error  
score = mean_squared_error(y_test, pred_test,  
squared=False)  
print("RMSE = {0:6.2f}".format(score))
```



線形回帰モデルの結果

305

決定係数 = 0.906

MAE = 8.77

RMSE = 10.95




ハードマージン線形SVRの結果

306

決定係数 = 0.907

MAE = 8.73

RMSE = 10.90




ソフトマージン線形SVRの結果

307

決定係数 = 0.885

MAE = 9.65

RMSE = 12.11




非線形SVR(RBF)の結果

308

決定係数 = 0.808

MAE = 10.93

RMSE = 15.62




非線形SVR(多項式)の結果

309

決定係数 = 0.088

MAE = 23.66

RMSE = 34.04




非線形SVR(シグモイド)の結果

310

決定係数 = -213

MAE = 381.1

RMSE = 521.5



線形/非線形SVRの結果

311

モデル	R^2	MAE	RMSE
線形/ハードマージン	0.907	8.73	10.90
線形/ソフトマージン	0.885	9.65	12.11
非線形/RBF	0.808	10.93	15.62
非線形/多項式	0.088	23.66	34.04
非線形/シグモイド	-213	381.1	521.5


MLP(ReLU,中間層2層)の結果

313

決定係数 = 0.705

MAE = 14.00

RMSE = 19.35



MLPの結果

314

カーネル	中間層 ユニット数	R^2	MAE	RMSE
シグモイド	中間層1層 (20,)	-0.043	29.10	36.41
	中間層2層 (50,20)	0.035	27.86	35.01
tanh	(20,)	0.105	26.83	33.72
	(50,20)	0.269	23.52	30.48
ReLU	(20,)	0.030	27.92	35.10
	(50,20)	0.705	14.00	19.35

自主學習用課題

自主課題2[1/3]

316

下記URLから入手できる米国カリフォルニア州の**住宅価格データセット**(housing.csv)を用いて, 以下の問いに
答えてください

<https://github.com/ageron/handson-ml2/tree/master/datasets/housing>

特徴量

特徴量であるが文字列なので除外

正解値

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
0	-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	452600.0	NEAR BAY
1	-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	358500.0	NEAR BAY
2	-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	352100.0	NEAR BAY
3	-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	341300.0	NEAR BAY
4	-122.25	37.85	52.0	1627.0	280.0	565.0	259.0	3.8462	342200.0	NEAR BAY
5	-122.25	37.85	52.0	919.0	213.0	413.0	193.0	4.0368	269700.0	NEAR BAY
6	-122.25	37.84	52.0	2535.0	489.0	1094.0	514.0	3.6591	299200.0	NEAR BAY
7	-122.25	37.84	52.0	3104.0	687.0	1157.0	647.0	3.1200	241400.0	NEAR BAY
8	-122.26	37.84	42.0	2555.0	665.0	1206.0	595.0	2.0804	226700.0	NEAR BAY
9	-122.25	37.84	52.0	3549.0	707.0	1551.0	714.0	3.6912	261100.0	NEAR BAY
10	-122.26	37.85	52.0	2202.0	434.0	910.0	402.0	3.2031	281500.0	NEAR BAY

出典: カリフォルニアの住宅価格データセット(R.K.Pace+, 1997)

1. 8つの特徴量の中から, **median_income**(収入の中央値)を**説明変数X**(スカラー)としたとき(**単回帰**), **median_house_value**(住宅価格の中央値)を**目的変数Y**として予測してください. ただし, 回帰モデルは, 授業で取り上げた各種モデル(LR, SVR, MLP)とします
2. 8つの特徴量の中から, 複数を説明変数X(ベクトル)としたとき(**重回帰**), 同様に**median_house_value**(住宅価格の中央値)を**目的変数Y**として予測してください. また単回帰と重回帰の性能差を確認してください

3. 決定係数等の性能指標を改善するために, 各種モデルにおいて**ハイパーパラメータの調整**を手動で行なってください

自主学習用の課題なので提出不要