

2024年度
機械学習
第6週

担当教員 小林 邦和

- 第1回 ガイダンス:機械学習の概要
- 第2回 線形モデルによるクラス分類(線形サポートベクトルマシン)
- 第3回 非線形モデルによるクラス分類1(非線形サポートベクトルマシン)
- 第4回 非線形モデルによるクラス分類2(ニューラルネットワーク)
- 第5回 線形モデルによる回帰(線形サポートベクトル回帰)
- 第6回 非線形モデルによる回帰(非線形サポートベクトル回帰)
- **第7回 課題1(クラス分類と回帰)**
- 第8回 線形モデルによる次元削減(主成分分析)
- 第9回 非線形モデルによる次元削減(オートエンコーダ)
- 第10回 非階層的クラスタリング(k平均法)
- 第11回 階層的クラスタリング(凝集クラスタリング)
- 第12回 課題2(次元削減とクラスタリング)
- 第13回 強化学習(Q学習法)
- 第14回 課題3(強化学習)
- 第15回 期末試験

新出の手法

- **k最近傍法**
クラス分類, 回帰への適用
- **課題**への取り組み
実データを用いた分類タスク, 回帰タスクの解決

k最近傍法

クラス分類

(k最近傍法)

アルゴリズム

1. データ集合 $D = \{(\mathbf{x}^p, y^p) \mid p = 1 \sim N\}$
 $\mathbf{x}^p = (x_1^p, x_2^p, \dots, x_n^p)$


2. 未知データ x と距離 d の近い順に, D のデータを並べ替える
 $\{(\mathbf{x}^1, y^1), (\mathbf{x}^2, y^2), \dots, (\mathbf{x}^N, y^N)\}$

$$d(\mathbf{x}, \mathbf{x}^p) = \sqrt{\sum_{i=1}^n (x_i - x_i^p)^2}$$

3. 先頭から k 個 $\{(x^1, y^1), (x^2, y^2), \dots, (x^k, y^k)\}$ の中で, 多数の y (1 or 0) を x のクラスラベルとする

2クラス分類のデータセット


327



総データ数: 26 (クラス0: 13, クラス1: 13)

k最近傍法の分類結果(k=1)


328



新規データ(☆)のラベル=最近傍のデータのクラスラベル

k最近傍法の分類結果(k=3)


329



新規データ(☆)のラベル=最近傍から第3近傍までのデータのクラスラベルの多数決

k最近傍法の分類結果(k=5)


330



新規データ(☆)のラベル=最近傍から第5近傍までのデータのクラスラベルの多数決

k最近傍法の決定境界

331



一様乱数で生成した点(feature 0, feature 1)のラベルをk最近傍法で定め, 決定境界を描く

回帰

(k最近傍法)

アルゴリズム

1. データ集合 $D = \{(\mathbf{x}^p, y^p) \mid p = 1 \sim N\}$

$$\mathbf{x}^p = (x_1^p, x_2^p, \dots, x_n^p)$$

2. 未知データ x と距離 d の近い順に, D のデータを並べ替える


$$\{(\mathbf{x}^1, y^1), (\mathbf{x}^2, y^2), \dots, (\mathbf{x}^N, y^N)\}$$

$$d(\mathbf{x}, \mathbf{x}^p) = \sqrt{\sum_{i=1}^n (x_i - x_i^p)^2}$$

3. 先頭から k 個 $\{(x^1, y^1), (x^2, y^2), \dots, (x^k, y^k)\}$ に対して, y^p ($p = 1 \sim N$) の平均値 $\hat{y} = \frac{1}{k} \sum_{i=1}^k y^i$ を出力値とする

1次元回帰予測のデータセット


334



データ数: 40 (横軸: 特徴量, 縦軸: 出力値)

k最近傍法の回帰結果(k=1)


335



新規データ(☆)の出力値=最も距離が近いデータの出力値

k最近傍法の回帰結果(k=3)


336



☆の出力値=最も距離に近い3つのデータの出力値の平均

k最近傍法の回帰結果(k=5)


337



☆の出力値=最も距離が近い5つのデータの出力値の平均

k最近傍法の予測結果

338



回帰曲線は k の増加, つまりモデルの複雑度が低くなることにより滑らかになる

訓練誤差: k の増加とともに増加

テスト誤差: k の増加とともに減少→増加

課題

[課題1] 分類タスク **難易度: 低**

目的: クラス分類の復習

テーマ: アヤメデータセットを用いた3クラス分類

[課題2] 回帰タスク **難易度: 中**

目的: 回帰の復習


テーマ: 糖尿病データセットを用いた疾患の進行状況予測

課題 I

分類タスク

(アヤメのデータセットを用いたクラス分類)

- 問題設定: **アヤメの分類**
- インスタンス数: **150**
- 特徴量数: **4** (花弁とガク片の長さ と 幅)
- ラベル: **3種類** (Setosa種, Virginica種, Versicolor種)
※インスタンス数は各種50個ずつ



3種類のアヤメ

課題I

343



Setosa種



Versicolor種



Verginica種

出典: Wikipedia

データ(先頭)

課題1

344

4個の特徴量

クラスラベル

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	Class
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa
5	5.4	3.9	1.7	0.4	setosa
6	4.6	3.4	1.4	0.3	setosa
7	5.0	3.4	1.5	0.2	setosa
8	4.4	2.9	1.4	0.2	setosa
9	4.9	3.1	1.5	0.1	setosa
10	5.4	3.7	1.5	0.2	setosa
11	4.8	3.4	1.6	0.2	setosa
12	4.8	3.0	1.4	0.1	setosa
13	4.3	3.0	1.1	0.1	setosa
14	5.8	4.0	1.2	0.2	setosa


```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 150 entries, 0 to 149
```

```
Data columns (total 5 columns):
```

```
#   Column                Non-Null Count  Dtype
```

```
---  -
```

```
0   sepal length (cm)  150 non-null   float64
```

```
1   sepal width (cm)   150 non-null   float64
```

```
2   petal length (cm)  150 non-null   float64
```

```
3   petal width (cm)   150 non-null   float64
```

```
4   Class              150 non-null   object
```

```
dtypes: float64(4), object(1)
```

```
memory usage: 6.0+ KB
```

4つの特徴量
欠損値なし
実数値

クラス

データの統計情報

課題 I

346

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

- **count**: 個数
- **mean**: 平均値
- **std**: 標準偏差
- **min**: 最小値
- **25%**: 第1四分位数
- **50%**: 第2四分位数(中央値)
- **75%**: 第3四分位数
- **max**: 最大値





	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
sepal length (cm)	1.000000	-0.117570	0.871754	0.817941
sepal width (cm)	-0.117570	1.000000	-0.428440	-0.366126
petal length (cm)	0.871754	-0.428440	1.000000	0.962865
petal width (cm)	0.817941	-0.366126	0.962865	1.000000

- 花弁の幅と花弁の長さの間に強い正の相関
- 花弁の長さとかく片の長さの間に強い正の相関
- 花弁の幅とかく片の長さの間に強い正の相関
- 花弁の長さとは花弁の幅の間に負の相関
- 花弁の幅とかく片の幅の間に弱い負の相関

相関係数による相関の強弱の判定

課題I


348

相関係数	相関の強さ(強弱)	散布図
0.7～1.0	強い正の相関あり	
0.4～0.7	正の相関あり	
0.2～0.4	弱い正の相関あり	
-0.2～0.2	相関なし(無相関)	
-0.4～-0.2	弱い負の相関あり	
-0.7～-0.4	負の相関あり	
-1.0～-0.7	強い負の相関あり	

特徴量間の相関係数(ヒートマップ)

課題1


349



特徴量の散布図行列

課題 I

350



- ハードマージン線形SVM
- ソフトマージン線形SVM
- 非線形SVM(カーネル: RBF, 多項式, シグモイド)
- 多層パーセプトロン(活性化関数: シグモイド, tanh, ReLU)
- k最近傍法

1. 混同行列

2. 正解率

課題2

回帰タスク

(糖尿病データセットを用いた疾患の進行状況の予測)

- 問題設定: 疾患(糖尿病)の進行状況予測
- インスタンス数: 442
- 特徴量数: 10
 - ✓ 基礎データの4項目
年齢(age), 性別(sex), BMI, 血圧(bp)
 - ✓ 血液検査の6項目
TC(s1), LDL(s2), HDL(s3), TCH(s4), LTG(s5), GLU(s6)
- 出力値: 1次元(1年後の疾患の進行状況)

データ(先頭15行)

課題2

355

10個の特徴量

出力値

	age	sex	bmi	bp	s1	s2	s3	s4	s5	s6	Y
0	0.038076	0.050680	0.061696	0.021872	-0.044223	-0.034821	-0.043401	-0.002592	0.019907	-0.017646	151.0
1	-0.001882	-0.044642	-0.051474	-0.026328	-0.008449	-0.019163	0.074412	-0.039493	-0.068332	-0.092204	75.0
2	0.085299	0.050680	0.044451	-0.005670	-0.045599	-0.034194	-0.032356	-0.002592	0.002861	-0.025930	141.0
3	-0.089063	-0.044642	-0.011595	-0.036656	0.012191	0.024991	-0.036038	0.034309	0.022688	-0.009362	206.0
4	0.005383	-0.044642	-0.036385	0.021872	0.003935	0.015596	0.008142	-0.002592	-0.031988	-0.046641	135.0
5	-0.092695	-0.044642	-0.040696	-0.019442	-0.068991	-0.079288	0.041277	-0.076395	-0.041176	-0.096346	97.0
6	-0.045472	0.050680	-0.047163	-0.015999	-0.040096	-0.024800	0.000779	-0.039493	-0.062917	-0.038357	138.0
7	0.063504	0.050680	-0.001895	0.066629	0.090620	0.108914	0.022869	0.017703	-0.035816	0.003064	63.0
8	0.041708	0.050680	0.061696	-0.040099	-0.013953	0.006202	-0.028674	-0.002592	-0.014960	0.011349	110.0
9	-0.070900	-0.044642	0.039062	-0.033213	-0.012577	-0.034508	-0.024993	-0.002592	0.067737	-0.013504	310.0
10	-0.096328	-0.044642	-0.083808	0.008101	-0.103389	-0.090561	-0.013948	-0.076395	-0.062917	-0.034215	101.0
11	0.027178	0.050680	0.017506	-0.033213	-0.007073	0.045972	-0.065491	0.071210	-0.096435	-0.059067	69.0
12	0.016281	-0.044642	-0.028840	-0.009113	-0.004321	-0.009769	0.044958	-0.039493	-0.030748	-0.042499	179.0
13	0.005383	0.050680	-0.001895	0.008101	-0.004321	-0.015719	-0.002903	-0.002592	0.038394	-0.013504	185.0
14	0.045341	-0.044642	-0.025607	-0.012556	0.017694	-0.000061	0.081775	-0.039493	-0.031988	-0.075636	118.0

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 442 entries, 0 to 441
```

```
Data columns (total 11 columns):
```

```
#   Column  Non-Null Count  Dtype
```

```
---  -
```

0	age	442 non-null	float64
1	sex	442 non-null	float64
2	bmi	442 non-null	float64
3	bp	442 non-null	float64
4	s1	442 non-null	float64
5	s2	442 non-null	float64
6	s3	442 non-null	float64
7	s4	442 non-null	float64
8	s5	442 non-null	float64
9	s6	442 non-null	float64

10	Y	442 non-null	float64
----	---	--------------	---------

```
dtypes: float64(11)
```

```
memory usage: 38.1 KB
```

10の特徴量
欠損値なし
実数値

出力値

データの統計情報

課題2

357

	age	sex	bmi	bp	s1	s2
count	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02
mean	-2.511817e-19	1.230790e-17	-2.245564e-16	-4.797570e-17	-1.381499e-17	3.918434e-17
std	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02
min	-1.072256e-01	-4.464164e-02	-9.027530e-02	-1.123988e-01	-1.267807e-01	-1.156131e-01
25%	-3.729927e-02	-4.464164e-02	-3.422907e-02	-3.665608e-02	-3.424784e-02	-3.035840e-02
50%	5.383060e-03	-4.464164e-02	-7.283766e-03	-5.670422e-03	-4.320866e-03	-3.819065e-03
75%	3.807591e-02	5.068012e-02	3.124802e-02	3.564379e-02	2.835801e-02	2.984439e-02
max	1.107267e-01	5.068012e-02	1.705552e-01	1.320436e-01	1.539137e-01	1.987880e-01

s3

s4

s5

s6

Y

count: 個数

mean: 平均値

std: 標準偏差

min: 最小値

25%: 第1四分位数

50%: 中央値

75%: 第3四分位数

max: 最大値

4.420000e+02	4.420000e+02	4.420000e+02	4.420000e+02	442.000000
-5.777179e-18	-9.042540e-18	9.293722e-17	1.130318e-17	152.133484
4.761905e-02	4.761905e-02	4.761905e-02	4.761905e-02	77.093005
-1.023071e-01	-7.639450e-02	-1.260971e-01	-1.377672e-01	25.000000
-3.511716e-02	-3.949338e-02	-3.324559e-02	-3.317903e-02	87.000000
-6.584468e-03	-2.592262e-03	-1.947171e-03	-1.077698e-03	140.500000
2.931150e-02	3.430886e-02	3.243232e-02	2.791705e-02	211.500000

2024年

1.811791e-01	1.852344e-01	1.335973e-01	1.356118e-01	346.000000
--------------	--------------	--------------	--------------	------------

疾患の進行状況(Y)との相関


Y	1.000000
bmi	0.586450
s5	0.565883
bp	0.441482
s4	0.430453
s6	0.382483
s1	0.212022
age	0.187889
s2	0.174054
sex	0.043062
s3	-0.394789
Name: Y, dtype: float64	

- ✓ BMI, LTG(s5), 血圧(bp), TCH(s4)と**正の相関**
- ✓ GLU(s6)やTC(s1)と**弱い正の相関**
- ✓ HDL(s3)と**負の相関**

相関係数のヒートマップ

課題2


359



散布図行列

課題2


360



各特徴量のヒストグラム

課題2



361




特徴量と出力値の散布図[1/3]

課題2


362



BMIと正の
相関



血圧(bp)と
正の相関





特徴量と出力値の散布図[2/3]


課題2

363


TC(s1)と弱い正の相関



HDL(s3)と負の相関



TCH(s4)と正の相関




特徴量と出力値の散布図[3/3]


課題2

364

LTG(s5)と
正の相関



GLU(s6)と
弱い正の相関



- 線形回帰モデル(最小二乗法)
- ハードマージン線形SVM
- ソフトマージン線形SVM
- 非線形SVM(カーネル: RBF, 多項式, シグモイド)
- 多層パーセプトロン(活性化関数: シグモイド, tanh, ReLU)
- k最近傍法

- 決定係數 R^2
- 平均平方二乘誤差(RMSE)
- 平均絕對誤差(MAE)

課題の提出方法と注意事項

課題1と2のプログラムファイル(**ipynb形式**)をそれぞれ**別ファイル**で提出すること

注意事項

- 最初に**学籍番号**と**氏名**をコメントで入れること
- 適宜**コメント**をつけること
- **すべての実行結果**を含めること
- 最後に**考察**をコメントで入れること

学籍番号
と氏名

機械学習 課題1

学籍番号: 2022311000

氏名: 県大 花子

コメント
(適宜)

混同行列の計算

プログラム
コード

```
[12]: from sklearn.metrics import confusion_matrix  
  
print("混同行列=\n{0}".format(confusion_matrix(y_test, pred_test)))
```

実行結果

```
混同行列=  
[[41  0]  
 [ 2 32]]
```

考察(最後)

▼ 考察

考察には以下のようなことをまとめて記述します.

- 1.得られた結果のまとめ(必要に応じて図表を作成)
- 2.結果から明らかになったこと
- 3.課題を通して考えたこと

- 提出先: **ユニパ**

- ※課題1と課題2の**提出先が異なる**ので注意

- ※ファイルサイズがユニパの制限容量(6MB)を超過する場合は, Teamsの個別チャットで提出

- 提出期限: **11月22日(金) 10時30分**

- ※期限厳守

剽窃行為

成績評価に関わる提出物に, 引用の形式を取らず, 著作権者に無断で著作物を複製・転載すること(著作権法違反)

具体例

デッドコピーはNG

他者との議論はOK

- ・ 他者(AI含む)の解答またはインターネット上の情報を利用し, 自分が作成したかのように見せかけること(剽窃)
- ・ 他者へ解答を与えること(剽窃幫助)

成績評価に関わる提出物で不正行為を行なった場合,
今期履修登録したすべての科目がD評価となる!

下記**2項目**の総合評価(シラバス記載の通り)

●期末試験【**60%**】

演習1～5

●課題【**40%**】

欠席6回以上

※出席が**2/3に満たない**場合は, 期末試験の受験資格なし(欠格条件)

未提出2回以上

※課題の提出が**2/3に満たない**場合は, 期末試験の成績に関わらず不合格